

تمرین سوم درس مبانی داده‌کاوی تیم Spark

مشخصات اعضای تیم:

اعضا	نقش	شماره دانشجویی	ایمیل	آیدی بله
ملیکا دهقانی	Data Steward	40313023	mdehghani@ec.iut.ac.ir	@melikadgi
مهسا توسلی	Analyst	40120033	m.tavassoli@ec.iut.ac.ir	@mahsa4tk
زهرا توکلی	Documenter	40120063	z.tavakoli@ec.iut.ac.ir	@z_ttavakoli

در این تمرین هدف انجام تحلیل اکتشافی داده ها (EDA) روی داده های قیمت مسکن در هند است. موارد اصلی انجام شده در این تمرین شامل بررسی ساختار داده ها و میزان کیفیت دیتاست، رسم و تحلیل نمودارهای ذکر شده در تمرین و بررسی همبستگی بین ویژگی ها و قیمت ملک است. در ادامه پاسخ سوالات تحلیلی آورده شده است:

سوال اول (بررسی وضعیت سلامت دیتاست):

ارزبایی سلامت دیتاست یکی از مراحل مهم در تحلیل داده است زیرا اگر داده ها از نظر کیفیت دچار مشکل باشند، نتایج تحلیل یا آموزش مدل های یادگیری ماشین نیز می توانند گمراه کننده باشند و نادرست انجام شوند. در این بخش وضعیت سلامت دیتاست قیمت مسکن بر اساس چند معیار بررسی می شود: کامل بودن داده ها، یکتایی رکوردها، بررسی مقادیر غیرعادی (Outliers) و مقیاس ویژگیها.

کامل بودن داده ها (Data Completeness): مقادیر گمشده در دیتاست زمانی رخ می دهند که برای یک ویژگی در برخی رکوردها مقداری ثبت نشده باشد. این موضوع می تواند به دلایلی مانند خطا در جمع آوری اطلاعات، نقص در ثبت اطلاعات یا حذف داده ها ایجاد شود. در این دیتاست هیچ مقدار گمشده ای وجود نداشت. بنابراین در مراحل بعدی پیش پردازش داده ها نیاز به هندل کردن مقادیر گمشده با روش مناسب نداریم.

یکتایی رکوردها و بررسی داده های تکراری: بررسی وجود داده های تکراری به این دلیل مهم است که وجود آنها می تواند باعث ایجاد سوگیری (Bias) در تحلیل های آماری شود و ممکن است باعث شوند داده های تکراری وزن بیشتری بگیرند و برخی الگوها بیش از حد واقعی شان تکرار شوند یا مدل سوگیری ای به سمت پیش بینی مقادیر پرتکرار پیدا کند. در این دیتاست دو نوع بررسی در این مورد انجام شد: بررسی رکوردهای کاملاً تکراری و بررسی وجود شناسه های تکراری. طبق بررسی های انجام شده هیچ رکورد کاملاً تکراری در دیتاست وجود نداشت. هم چنین شناسه ها یکتا بودند و هیچ کدام بیش از یکبار تکرار نشده بودند.

بررسی وجود مقادیر غیرعادی (Outliers): با توجه به مقادیر 5-number summary ویژگی ها پی می بریم برخی ویژگی ها مانند تعداد اتاق خواب (number of bedrooms) یا مساحت زمین (lot Area) یا مساحت قابل سکونت (living Area) دارای مقادیر حداکثر بسیار بزرگ نسبت به میانه و Q1 و Q3 هستند. اگر حد پایین و بالای دورافتادگی داده ها را به صورت زیر در نظر بگیریم

$$IQR = Q3 - Q1$$

$$lower\ bound = Q1 - 1.5IQR, upper\ bound = Q3 + 1.5IQR$$


متوجه می شویم که مثلاً در ستون تعداد اتاق خواب که ماکزیمم مقدار برابر 33 است در صورتی که IQR برابر 1 می باشد داده پرت داریم. به طور طبیعی هم تعداد 33 اتاق خواب برای یک خانه غیر عادی است و این عدد ممکن است به علت خطای اپراتور به اشتباه درج شده باشد و خانه ای با این مشخصات نداشته باشیم.

بنابراین در این دیتاست مقادیر پرت وجود دارند که در مراحل بعدی باید صحت سنجی و در صورت لزوم حذف شوند یا از الگوریتم هایی که به outlier ها حساس نیستند باید استفاده کنیم.


بررسی مقیاس ویژگی ها: بررسی مقیاس ویژگی ها نشان می دهد ویژگیها scale های بسیار متفاوتی دارند. مثلا ویژگی ای مانند تعداد اتاق خواب دارای مقادیر یک یا دو رقمی ولی مساحت زمین شامل مقادیر 4 یا حتی 7 رقمی است. بنابراین الگوریتم هایی که وابسته به محاسبه فاصله بین رکوردها هستند مانند خوشه بندی های مبتنی در فاصله داده تا مرکز خوشه و... دچار مشکل می شوند. بنابراین داده ها باید نرمالسازی شوند. (با توجه به این موضوع فواصل اقلیدسی و منهتن محاسبه شده بین گران ترین و ارزان ترین خانه هم از جهاتی قابل استناد نیست. چون ویژگی های با مقیاس بالا بیش از ویژگی هایی با مقیاس پایین مانند تعداد اتاق خواب روی آنها اثر گذاشته اند. ممکن است گران ترین خانه تعداد اتاق خواب خیلی بیشتری نسبت به ارزان ترین خانه داشته باشد ولی چون مقیاس این ویژگی نسبت به سایر ویژگیها کوچک تر است این تفاوت نمود زیادی در عدد حاصل پیدا نمی کند).

سوال دوم (تفسیر نمودار های رسم شده توسط Analyst):

نمودار Boxplot ویژگی price: با توجه به این نمودار متوجه می شویم اختلاف Q1 و Q3 در این ویژگی کم است حدود 75 درصد داده ها قیمتی کمتر از 1 میلیون دلار دارند و در بازه قیمت کوچکی فشرده شده اند. خانه هایی که قیمتی حداکثر حدود 1.5 میلیون دلار دارند دارای قیمتی طبیعی هستند ولی سایر خانه هایی که با نقطه روی نمودار نشان داده شده اند دارای قیمت های غیر عادی و پرت هستند.



نمودار هیستوگرام ویژگی built year: این نمودار تعداد خانه های ساخته شده در بازه های زمانی 5 ساله را نشان می دهد. طبق نمودار تعداد خانه های ساخته شده با زمان به طور کلی روند صعودی داشته است که می تواند به دلیل پیشرفت تکنولوژی های عمرانی و افزایش سرعت ساخت ساختمان و افزایش جمعیت و رشد شهر نشینی رخ داده باشد. در برخی بازه های زمانی مانند سالهای 1930 تا 1940 شاهد کاهش ساخت و ساز هستیم که می تواند مثلا به علت رکود اقتصادی در سالهای قبل از جنگ جهانی دوم باشد. (جنگ جهانی دوم در سالهای 1939 تا 1945 به وقوع پیوست.) هم چنین نمودار نشان می دهد دیتاست شامل تنوع در سال ساخت خانه ها می باشد و فقط خانه های قدیمی تر یا جدید تر در دیتاست وجود ندارد. هرچند که تعداد خانه های جدیدتر نسبت به خانه های قدیمی تر بیش تر است. این تنوع داده به آموزش مدل های بهتر و جامع تر کمک می کند.




نمودار Scatter plot برای living area و price: با توجه به اینکه این scatter plot تقریباً مشابه یک خط با شیب مثبت است نتیجه می گیریم بین living area و price همبستگی مثبت وجود دارد و چون شیب نمودار تقریباً خوب است نتیجه می گیریم این همبستگی تقریباً قوی است. علت اینکه نمودار کاملاً به صورت خط نیست و حالت مثلثی دارد این است که معیارهای دیگری مانند امتیاز یا مساحت زمین هم در قیمت خانه اثر گذارند که باعث می شوند قیمت فقط به صورت یک تابع خطی از مساحت قابل سکونت نباشد. به همین دلیل در نمودار خانه هایی با مساحت سکونت یکسان ولی قیمت های متفاوت قابل مشاهده است. یا مثلاً خانه ای با مساحت حدود 14000 ولی قیمت بسیار پایین تر نسبت به خانه هایی با مساحت کمتر داریم که نشان می دهد عوامل دیگری هم در تعیین قیمت خانه نقش دارند.




تصویر heat map همبستگی بین ویژگی ها: در این نمودار رنگ زرد نشان دهنده همبستگی مثبت 1 و رنگ بنفش نشان دهنده همبستگی -1 بین دو متغیر است. همان طور که مشاهده می کنیم قطر اصلی ماتریس تماماً زرد است چون هر متغیر با خودش همبستگی 1 دارد. هم چنین متغیر id با اکثر ویژگی ها هم بستگی منفی دارد یا بدون همبستگی است چون یک شناسه است که مقدار آن به سایر ویژگی ها بستگی ندارد و بهتر بود پیش از محاسبه همبستگی از داده ها حذف شود. ویژگی کد پستی هم به طور مشابه با سایر ویژگی ها همبسته نیست و بهتر بود حذف شود. بین برخی ویژگی ها مثل area of the house و living area هم بستگی مثبت می بینیم که کاملاً منطقی است چون هر چه مساحت قابل سکونت خانه بیشتر باشد مساحت کل آن هم بیشتر است. برخی ویژگی ها مثل تعداد مدارس نزدیک و فاصله از فرودگاه با هیچ یک از ویژگی های دیگر غیر از خودشان همبستگی مثبت نداشته اند که منطقی است زیرا ویژگی های خانه مانند تعداد اتاق یا مساحت به این دو ویژگی مرتبط نیست. البته باید توجه کنیم

در همبستگی وابستگی های خطی ارزیابی می شوند مثلا در نمودار هم بستگی خطی بین قیمت و تعداد مدارس نزدیک و فاصله تا فرودگاه نمی بینیم ولی دلیل نمی شود این ویژگی ها بر قیمت اثرگذار نباشند و ممکن است قیمت به صورت غیر خطی به آنها وابسته باشد. هم چنین بین **built year** و ویژگی هایی مانند تعداد طبقات، تعداد اتاق خوابها، امتیاز، مساحت و حتی طول جغرافیایی همبستگی کمی مشاهده می شود که منطقی است. چون تعداد طبقات ساختمانها، تعداد اتاقها، محل ساخت ساختمانها و مساحت ممکن است دو طول زمان تغییر کند. مثلا ساختمان های جدیدتر تعداد طبقات بیشتری دارند. بین سایر ویژگی ها هم هم بستگی های معناداری می توان یافت که در اینجا فضای کافی جهت ذکر همه آنها نیست مثلا سال ساخت در قیمت اثر ندارد یا مساحت قابل سکونت با قیمت همبستگی مثبت دارد.




نمودار (هیستوگرام) توزیع قیمت مسکن: با توجه به این نمودار مشاهده می کنیم توزیع قیمت مسکن یک توزیع نرمال نیست و چولگی به سمت راست دارد.



نمودار Q-Q برای ویژگی های living area و price: نمودار Q-Q برای بررسی اینکه آیا توزیع مورد نظر (در اینجا توزیع قیمت و مساحت قابل سکونت خانه ها) با توزیع نرمال سازگار است یا خیر استفاده می شود. اگر نقاط روی خط قرار بگیرند توزیع به نرمال نزدیک است و اگر نقاط دو سر نمودار از خط فاصله بگیرند نشان دهنده چولگی است. بنابراین طبق نمودار هیچ یک از دو ویژگی

توزیع نرمال ندارند و اگر می‌خواهیم از الگوریتم‌هایی روی آنها استفاده کنیم که پیش‌فرض آنها نرمال بودن ویژگی‌ها است باید به این موضوع که پیش‌فرض الگوریتم وجود ندارد دقت کنیم.



سوال سوم (پاسخ سوالات مطرح شده با توجه به ماتریس همبستگی):

سوال a: با توجه به اینکه میزان همبستگی قیمت و متراژ بنا 0.71 ولی همبستگی قیمت و سال بازسازی 0.13 و حتی همبستگی قیمت و living area renov هم حدود 0.58 است، قیمت با متراژ بنا همبستگی بیشتری دارد و در نتیجه متراژ بنا تاثیر بیشتری بر قیمت ملک دارد.

سوال b: living area بیشترین همبستگی را با قیمت ملک دارد که برابر 0.71 است.


سوال c: این دو ویژگی همبستگی حدود 0.44 دارند که چون مثبت است یعنی هر چه سال ساخت خانه بیشتر و خانه جدید تر باشد امتیاز آن بیشتر است چون احتمالاً کیفیت ساخت بالاتری دارد. ولی این همبستگی خیلی قوی نیست چون موارد دیگری مانند مساحت خانه و تعداد اتاقها یا سرویس‌های بهداشتی، بازسازی یا عدم بازسازی هم روی امتیاز اثر دارند. مثلاً ممکن است یک خانه قدیمی بازسازی شود و امتیاز زیادی بگیرد.

سوال چهارم (تحلیل نمودار Q-Q): پاسخ این سوال در بخش سوال دوم آورده شده است.

سوال پنجم (تحلیل افزایش قیمت خانه در دوره‌های مختلف ساخت و ساز):

از روی خروجی بخش 2.2 به تنهایی نمی‌توان افزایش قیمت خانه در دوره‌های مختلف را بررسی کرد. البته می‌توان گفت که مثلاً در سالهای 1900 تا 1920 با توجه به اینکه تعداد خانه‌ها کمتر است ممکن است قیمت بیشتری 1930 تا 1940 داشته باشند ولی برای بررسی دقیق‌تر من نمودار میانگین قیمت خانه در هر بازه زمانی را رسم کرده‌ام. در این نمودار مشاهده می‌کنیم که در

بازه 1900 تا 1910 بیشترین قیمت خانه را داشته ایم. در بازه 1940 تا 1950 شاید به دلیل جنگ جهانی یا دلایل دیگر قیمت خانه بسیار کاهش یافته است اما به تدریج شروع به رشد کرده و افزایش یافته است. خانه های جدید تر شاید به دلیل کیفیت ساخت بهتر یا ... قیمت های بالاتری داشته باشند با اینکه شاهد افزایش تعداد خانه ها هستیم.



پاسخ سوالات 1.4 و 1.6:

1.4: چرا محاسبه خلاصه ۵ عددی برای بعضی ویژگی های عددی بی معنی است؟

در این دیتاست، برخی متغیرها با وجود اینکه عددی هستند، محاسبه Minimum, Q1, Median, Q3, Maximum برای آن ها منطقی نیست و می تواند گمراه کننده باشد. مانند متغیرهای شناسه و کدها مثل ویژگی id که مقدار آن صرفاً یک برچسب برای هر خانه استمیانگین یا میانه آن هیچ معنی واقعی ندارد و یا کد پستی که اگرچه عددی است، اما یک متغیر کیفی محسوب می شود. محاسبه میانه یا چارک برای آن اشتباه است، چون این اعداد فقط یک برچسب برای موقعیت مکانی هستند و ترتیب عددی آن ها معنی دار نیست. یا متغیرهای زمانی (سال ساخت و سال بازسازی). سال ساخت خانه معمولاً در چند بازه خاص متمرکز است. گرفتن میانگین سال ساخت (مثلاً ۱۹۶۷) لزوماً نشان دهنده سال ساخت یک خانه معمولی نیست. همچنین در متغیرهای زمانی، صفر مطلق معنی ندارد (سال ۲۰۰۰ دو برابر سال ۱۰۰۰ نیست). یا در رابطه با سال بازسازی اکثر خانه ها بازسازی نشده اند (مقدار صفر) و تعداد کمی در سال های خاص بازسازی شده اند. میانگین گرفتن از این متغیر کاملاً گمراه کننده است. یا متغیرهای ترتیبی و دودویی مانند condition و grade. این دو متغیر کیفی ترتیبی هستند. ترتیب آن ها مهم است، ولی فاصله بین مقادیر (مثلاً تفاوت ۲ با ۳ در مقایسه با ۴ با ۵) قابل قیاس نیست. پس میانگین گرفتن از آن ها معنی ندارد. waterfront present هم یک متغیر دودویی است و بهترین روش برای تحلیل آن، استفاده از جدول فراوانی و درصدهاست. بنابراین خلاصه ۵ عددی فقط برای متغیرهای کمی که مقیاس پیوسته و معنی دار دارند مناسب است. برای متغیرهای اسمی (مثل کد پستی)، ترتیبی (مثل درجه خانه)، زمانی (مثل سال ساخت) و دودویی، بهتر است از جدول فراوانی، نمودار میله ای یا هیستوگرام استفاده شود.

1.6: ابتدا ۵ درصد از مقادیر ستون living area به صورت تصادفی حذف شد. سپس با دو روش binning این مقادیر پر شدند:

- روش اول (Binning با میانگین هر دسته - Bin Mean): داده‌ها به ۱۰ دسته تقسیم شدند و مقادیر مفقود با میانگین دسته مربوطه پر شدند.
- روش دوم (Binning با میانه هر دسته - Bin Median): داده‌ها به ۱۰ دسته تقسیم شدند و مقادیر مفقود با میانه هر دسته پر شدند.

در این دیتاست، به دلیل اینکه مقادیر حذف شده تصادفی بودند و میانه و میانگین دسته‌ها به مقادیر اصلی نزدیک بودند، خلاصه ۵ عددی تقریباً بدون تغییر باقی ماند. روش اول توزیع داده را به سمت میانگین‌های دسته‌ای هموار می‌کند و می‌تواند واریانس را کاهش دهد. روش دوم مقاوم‌تر در برابر داده‌های پرت است و اگر داده‌های حذف شده پرت باشند، این روش بهتر عمل می‌کند. ولی نکته مهم این است که در دنیای واقعی، اگر داده‌های گمشده سیستماتیک باشند برای مثال خانه‌های بزرگ‌تر تمایل به عدم ثبت متراژ داشته باشند این روش‌ها می‌توانند باعث اریبی شوند و مثلاً میانگین در دو حالتی که همه مقادیر را داریم یا مقادیر گمشده را با این روش‌ها پر کرده ایم، می‌تواند متفاوت شود.

پاسخ سوال 2.5:

با توجه به اینکه دیتاست، کد پستی خانه‌ها را دارد پس می‌توان محله‌ها را خوشه‌بندی کرد و بررسی کرد که در چه محله‌هایی خانه‌های گرانتری وجود دارد یا مساحت خانه‌ها در کدام محله بیشتر است و با استفاده از این الگو‌ها پیش‌بینی کرد در آینده کدام محله‌ها محبوبیت بیشتری پیدا می‌کنند. علاوه بر این می‌توان، با استفاده از سال ساخت تحلیل کرد که در بازه‌های زمانی ساخت و ساز چه تغییری در معماری و نقشه‌های خانه ایجاد شده است. برای مثال، با گذشت زمان مساحت خانه‌ها چه تغییری کرده است و در آینده قرار است چه تغییری بکند. همچنین، می‌توان بررسی کرد که با گذر زمان وضعیت خانه‌ها (condition of the house) در محله‌های مختلف، چه تغییری کرده است، مثلاً هر چه خانه نوساز تر باشد وضعیت بهتری دارد یا یک خانه بازسازی شده هم به همان اندازه خوب است.