

تیم **Spark** تکلیف چهارم

مشخصات اعضای تیم:

اعضا	نقش	شماره دانشجویی	ایمیل	آیدی بله
ملیکا دهقانی	Analyst	۴۰۳۱۳۰۲۳	mdehghani@ec.iut. ac.ir	@melikadgi
مهسا توسلی	Documenter	۴۰۱۲۰۰۳۳	m.tavassoli@ec.iut. ac.ir	@mahsa4tk
زهرا توکلی	Data Steward	۴۰۱۲۰۰۶۳	z.tavakoli@ec.iut.ac .ir	@z_ttavakoli

بخش Data Steward:

۱. در این بخش، کیفیت داده‌های دیتاست مورد بررسی قرار گرفت. همان‌طور که از خروجی کد مشخص است، این دیتاست هیچ داده گمشده‌ای ندارد. همچنین نتایج نشان می‌دهد که ۷۵۹ سطر تکراری در داده‌ها وجود دارد که مربوط به تراکنش‌هایی هستند که از نظر شماره مشتری، تاریخ و نام کالا کاملاً یکسان‌اند.



برای بررسی داده‌های پرت، ابتدا تعداد تراکنش‌های هر مشتری محاسبه شد و سپس با استفاده از روش IQR، مشتریانی که تعداد تراکنش‌های آن‌ها به‌طور غیرعادی زیاد یا کم بود شناسایی شدند. با توجه به نتایج، این دیتاست شامل ۳۸۹۸ مشتری است که هر مشتری به‌طور میانگین حدود ۱۰ تراکنش ثبت کرده است. همچنین ۶۰ مشتری به‌عنوان داده پرت شناسایی شدند که تعداد تراکنش‌های آن‌ها در محدوده تعیین‌شده نبوده است. سپس، اعتبار مقادیر ستون تاریخ بررسی شد و هیچ تاریخ نامعتبری در دیتاست مشاهده نشد. همچنین طول نام کالاها برای شناسایی مقادیر غیرعادی مورد ارزیابی قرار گرفت. نتایج نشان می‌دهد که میانگین طول نام کالاها حدود ۱۰ کاراکتر است و هیچ موردی با طول کمتر از ۲ یا بیشتر از ۳۰ کاراکتر مشاهده نشد.

۲. برای پاسخ به این سؤال، فراوانی کالاهای موجود در دیتاست بررسی شد. نتایج نشان می‌دهد که این دیتاست شامل ۱۶۷ کالای منحصربه‌فرد و ۳۸۷۶۵ تراکنش است. به‌طور میانگین، هر کالا حدود ۲۳۲ بار در تراکنش‌ها مشاهده شده است.

همان‌طور که در خروجی کد مشاهده می‌شود، ۵۱ کالا در حدود ۸۰ درصد تراکنش‌ها حضور دارند. این کالاها حدود ۳۰ درصد از کل کالاهای موجود در دیتاست را تشکیل می‌دهند. همچنین، حداقل تعداد تکرار هر یک از این کالاها حدود ۲۲۷ بار است که کمتر از میانگین است.

برای مشخص کردن داده‌های پرت، حداقل تکرار برابر ۱۰۰۰ بوده است و ۷ تا از داده‌ها به‌عنوان داده‌های پرت با تکرار بالا شناسایی شده‌اند. (یعنی حداقل در حدود ۲.۵ درصد از تراکنش‌ها، این کالاها مشاهده شده‌اند).

نمودار زیر پرتکرارترین کالاهای موجود در دیتاست را نمایش می‌دهد. همان‌طور که مشاهده می‌شود؛ تعداد محدودی از کالاها فراوانی بسیار بالاتری نسبت به سایر کالاها دارند و سهم قابل توجهی از تراکنش‌ها را به خود اختصاص داده‌اند. این موضوع نشان می‌دهد که توزیع فراوانی کالاها یکنواخت نبوده و برخی کالاها از محبوبیت بیشتری برخوردار هستند.



با توجه به نمودار های بالا، نمودار سمت چپ، توزیع فراوانی تمامی کالاها را نمایش می دهد. در نمودار سمت راست، به منظور بررسی دقیق تر کالاهای کم تکرار، کالاهایی با فراوانی بیش از ۱۰۰ حذف شدند. نتایج نشان می دهد که بخش عمده ای از کالاها در تعداد تقریباً کمی از تراکنش ها حضور دارند و تنها تعداد اندکی از کالاها فراوانی بالایی دارند. این موضوع بیانگر وجود تعداد زیادی کالا با تقاضای کم در دیتاست است.

۳. در این سؤال، بررسی شد که آیا یک کالا به دلیل تفاوت در نحوه نگارش در ستون `itemDescription` چندین بار به عنوان کالاهای متفاوت شمارش شده است یا خیر. برای این منظور، وجود `space` اضافی در ابتدا و انتهای نام کالاها، `space` اضافه بین کلمات، و تفاوت در حروف بزرگ و کوچک بررسی شد. نتایج نشان می دهد که هیچ کالایی به دلیل تفاوت در نحوه نگارش چندبار ثبت نشده است و تعداد کالاهای منحصر به فرد

قبل و بعد از استانداردسازی تغییری نکرد و برابر با ۱۶۷ باقی ماند. البته ۴۴۰ رکورد دارای فاصله اضافی در ابتدا یا انتهای نام کالا بودند که با فرآیند استانداردسازی اصلاح شدند.

۴. در انبار داده‌ای که برای تحلیل فروش طراحی شده است، جدول اصلی FactSales شامل جزئیات هر تراکنش یعنی تاریخ، شماره مشتری، شعبه و مبلغ خرید است. در مفاهیم مربوط به مکعب داده (Data Cube)، به این سطح از داده‌ها که هیچ جمع‌بندی‌ای روی آنها انجام نشده و همه ابعاد با جزئیات کامل وجود دارند، Base Cuboid گفته می‌شود. در این مثال Base Cuboid همان محتوای جدول FactSales با ۴ ستون و ۲ رکورد است.

مبلغ خرید	شعبه	شماره مشتری	تاریخ
۱۰۰۰	۱	۱	۱۴۰۰/۱۰/۱
۲۰۰۰	۱	۲	۱۴۰۰/۱۰/۱

در مقابل بالاترین سطح تجمیع Apex Cuboid است که در آن هیچ کدام از ابعاد (تاریخ، مشتری، شعبه) در نظر گرفته نمی‌شوند و فقط مقدار کلی معیار که در اینجا مجموع کل فروش است محاسبه می‌شود. بنابراین Apex Cuboid یک عدد است که برابر با مجموع ۱۰۰۰ و ۲۰۰۰ یعنی ۳۰۰۰ می‌باشد. بین این دو سطح cuboid های میانی وجود دارند که تجمیع را روی یک یا چند بعد خاص (مثلاً جمع فروش به تفکیک شعبه یا به تفکیک ماه) انجام می‌دهند.

مجموع مبلغ خرید
۳۰۰۰

Apex Cuboid

۵. پاسخ این سؤال در نوتبوک آورده شده است.

بخش Analyst

۱. برای اجرا دو الگوریتم **Apriori** و **FP-Growth**، ابتدا داده‌ها بر اساس شماره مشتری و تاریخ خرید گروه‌بندی می‌شوند. سپس تمام کالاهای هر خرید در قالب یک لیست قرار می‌گیرند. بعد از آن، با استفاده از **TransactionEncoder**، داده‌ها به صورت **One-Hot Encoding** تبدیل می‌شوند. همچنین پارامتر **min_support** برابر ۰.۰۵ می‌باشد و برای **Confidence**، حداقل مقدار برابر ۰.۱ می‌باشد.

با اجرای دو الگوریتم **Apriori** و **FP-Growth** مشاهده شد که هر دو الگوریتم با پارامترهای یکسان، تعداد یکسانی از **Frequent Itemsets** (۱۲۶) و **Association Rules** (۱۹) استخراج کردند. پس هر دو الگوریتم نتایج یکسانی تولید کردند و تفاوت اصلی آن‌ها در روش اجرا و سرعت پردازش است، نه در قوانین استخراج‌شده. همچنین، پس از افزودن ۵٪ رکورد تکراری نیز این مقادیر تغییری نکردند. زیرا معیار **Support** به صورت نسبی محاسبه می‌شود و افزودن این رکوردهای تکراری، فراوانی نسبی آیت‌ها را به طور محسوسی تغییر نداده است. این موضوع نشان می‌دهد که اضافه شدن تعداد کمی رکورد تکراری، فراوانی نسبی آیت‌ها را به اندازه‌ای تغییر نمی‌دهد که مجموعه قوانین استخراج‌شده تغییر کند.

۲. پس از اجرای الگوریتم **Apriori** و مرتب‌سازی قوانین بر اساس معیار **Lift**، مهم‌ترین قوانین انجمنی به دست آمدند.

antecedents	consequents	antecedent support	consequent support	support	confidence	lift
(frankfurter)	(other vegetables)	0.037760	0.122101	0.005146	0.136283	1.116150
(bottled beer)	(whole milk)	0.045312	0.157923	0.007151	0.157817	0.999330
(sausage)	(whole milk)	0.060349	0.157923	0.008955	0.148394	0.939663
(newspapers)	(whole milk)	0.038896	0.157923	0.005614	0.144330	0.913926
(domestic eggs)	(whole milk)	0.037091	0.157923	0.005280	0.142342	0.901341

همانطور که در تصویر مشاهده می‌شود، تنها قانون **Frankfurter → Other Vegetables** دارای **lift** بزرگ‌تر از ۱ است؛ بنابراین، بین خرید سوسیس فرانکفورتر و سبزیجات ارتباط مثبت وجود دارد و خرید یکی، احتمال خرید دیگری را افزایش می‌دهد. این قانون دارای **Support** برابر با ۰.۰۰۵۱۴۶ و

Confidence برابر با ۰.۱۳۶۲۸۳ نیز بود که نشان می‌دهد اگرچه این رابطه مثبت است، اما میزان وقوع و قدرت پیش‌بینی آن پایین است.



همچنین، سایر قوانین استخراج‌شده از جمله Bottled Beer → Whole Milk،

Sausage → Whole Milk، Newspapers → Whole Milk و

Domestic Eggs → Whole Milk دارای مقادیر lift نزدیک به ۱ بودند. علاوه بر این، سایر قوانین برتر نیز مقدار lift کمتر از ۱ داشتند. این نتایج نشان می‌دهد که بین این کالاها ارتباط مثبت و معناداری وجود ندارد و خرید یک کالا موجب افزایش احتمال خرید کالای دیگر نمی‌شود. همچنین مقادیر Confidence نیز پایین هستند که نشان می‌دهد قدرت پیش‌بینی این قوانین زیاد نیست.

۳. کالاهای پرتکرار مانند Whole Milk و Other Vegetables در تعداد زیادی از تراکنش‌ها حضور دارند. حذف این کالاها ممکن است باعث کاهش تعداد قوانین تکراری شود، اما در عین حال احتمال از دست رفتن اطلاعات ارزشمند و الگوهای مهم خرید را نیز افزایش می‌دهد. بنابراین حذف کامل این اقلام خوب نیست. بهتر است به جای حذف آن‌ها، از معیارهایی مانند Lift، Kulczynski و Imbalance Ratio برای تشخیص قوانین مفید استفاده شود. به این ترتیب قوانین معنادار حفظ شده و قوانین ضعیف‌تر قابل فیلتر کردن خواهند بود.

۴. برای بررسی وجود الگوی زمانی برای خرید، تعداد تراکنش‌ها بر حسب سال، ماه و روزهای هفته محاسبه شده است.



Year	
2014	18277
2015	20488

همانطور که مشاهده می‌شود، تعداد تراکنش‌ها در سال ۲۰۱۵ نسبت به سال ۲۰۱۴ افزایش یافته است. همچنین، با بررسی تراکنش‌ها در ماه‌های مختلف، ماه آگوست (۸) بیشترین فروش را داشته است و کمترین تعداد در ماه فوریه (۲) بوده است. الگوی خرید در ماه‌های مختلف یکسان نیست و می‌تواند ناشی از عوامل فصلی،

تعطیلات یا تغییر رفتار مشتریان باشد. این فروشگاه، در روز دوشنبه کمترین فروش و روز پنجشنبه بیشترین فروش را داشته است. البته که اختلاف تراکنش ها برای روز های هفته زیاد نیست و تقریباً یکنواخت است.

۵. برای دسته بندی مشتریان از الگوریتم **k-means** استفاده شد و در ۴ گروه دسته بندی شدند.

خوشه	تعداد مشتری
Cluster 0	1339
Cluster 1	2527
Cluster 2	20
Cluster 3	12

نتایج نشان می دهد که بیشتر مشتریان در خوشه های ۰ و ۱ قرار گرفته اند، در حالی که خوشه های ۲ و ۳ تعداد بسیار کمتری مشتری را شامل می شوند. این موضوع نشان می دهد که خوشه های ۲ و ۳ احتمالاً گروه های خاصی از مشتریان با الگوی خرید متفاوت را نمایش می دهند.

با بررسی کالاهای پرتکرار در هر خوشه، الگو های خرید را به دست می آید. خوشه ۰ کالاهایی مانند **Whole Milk, Other Vegetables, Rolls/Buns, Soda** و **Yogurt** بیشترین میزان خرید را دارند. این الگوی خرید نشان می دهد که مشتریان این خوشه کالاهای متنوع و پرمصرف روزانه را خریداری می کنند؛ بنابراین، می توان این گروه را مشتریان پرمصرف در نظر گرفت.

همچنین، در خوشه ۱ نیز کالاهای **Whole Milk, Rolls/Buns, Other Vegetables, Soda** و **Yogurt** بیشترین فراوانی را دارند. اگرچه الگوی خرید این خوشه شباهت زیادی به خوشه ۰ دارد، اما میانگین میزان خرید کالاها کمتر است؛ بنابراین، این خوشه را می توان گروه مشتریان عادی در نظر گرفت.

خوشه ۲ تنها ۲۰ مشتری را شامل می شود و کالاهای **Skin Care, Whole Milk, Other Vegetables, Rolls/Buns** و **Pip Fruit** بیشترین میزان خرید را در این خوشه دارند. وجود محصولات مراقبت شخصی در میان کالاهای پرتکرار نشان می دهد که این گروه دارای الگوی خرید متفاوتی نسبت به سایر مشتریان است.

خوشه ۳ با ۱۲ مشتری کوچک ترین خوشه را تشکیل می دهد. کالاهای پرتکرار این خوشه شامل **Cream, Sausage, Whole Milk, Other Vegetables, Newspapers** هستند. خرید همزمان مواد غذایی و کالاهایی مانند روزنامه، نشان دهنده رفتار خرید متمایز این گروه از بقیه مشتریان است.

۶. در این سؤال مقادیر Lift، Kulczynski، Imbalance Ratio برای ۱۰ قاعده برتر الگوریتم Apriori محاسبه شده است.

	antecedents	consequents	lift	kulczynski	Imbalance Ratio
5	(frankfurter)	(other vegetables)	1.116150	0.089214	0.545140
0	(bottled beer)	(whole milk)	0.999330	0.101549	0.574301
14	(sausage)	(whole milk)	0.939663	0.102551	0.466156
7	(newspapers)	(whole milk)	0.913926	0.089939	0.622510
4	(domestic eggs)	(whole milk)	0.901341	0.087887	0.636844
6	(frankfurter)	(whole milk)	0.885388	0.086628	0.631099
11	(pork)	(whole milk)	0.855703	0.083437	0.635948
10	(pip fruit)	(whole milk)	0.854071	0.088387	0.543362
3	(citrus fruit)	(whole milk)	0.852259	0.089936	0.513930
15	(shopping bags)	(whole milk)	0.844887	0.086815	0.554027

معیار Kulczynski میانگین احتمال وقوع هر یک از دو بخش قانون در صورت وقوع بخش دیگر را نشان می‌دهد و هرچه مقدار آن بزرگ‌تر باشد، ارتباط بین دو مجموعه آیت‌م قوی‌تر است. همچنین معیار Imbalance Ratio میزان عدم تعادل بین فراوانی antecedent و consequent را اندازه‌گیری می‌کند؛ مقادیر نزدیک به صفر نشان‌دهنده تعادل بیشتر و مقادیر بزرگ‌تر بیانگر عدم تعادل بیشتر در قانون هستند.

همانطور که مشاهده می‌شود؛ مقدار Kulczynski برای این قواعد حدود ۰.۰۸ تا ۰.۱ می‌باشد که مقدار کمی است؛ در نتیجه وابستگی دوطرفه نسبتاً ضعیف است. با این حال، قانون (sausage → whole milk) با مقدار ۰.۱۰۲۵ بهترین عملکرد را از این نظر دارد. همچنین، معیار Imbalance Ratio نشان می‌دهد که همین قانون با مقدار ۰.۴۶۶ متعادل‌ترین رابطه را دارد، در حالی که قوانینی مانند (domestic eggs → whole milk) و (pork → whole milk) با مقادیر بالاتر از ۰.۶۳ از عدم تعادل بیشتری برخوردارند.

سؤالات بخش Documenter:

۱. برای بررسی اینکه خوشه ها وزن آماری مستقلی دارند؛ آزمون χ^2 را انجام شده و مقدار silhouette score (۰.۰۲۲۷) نیز حساب شده است.

چون مقدار silhouette score کم می باشد؛ پس این خوشه بندی به خوبی گروه ها را تشخیص نداده است. همچنین با توجه به خروجی زیر، دو محصول cream و skin care نمره χ^2 مشابه و بسیار غیرعادی (۳۸۹۸) و P-value صفر دارند که نشان دهنده این است که در خوشه ۳ وجود cream, در خوشه ۲ وجود skin care باعث دسته بندی شده است. در ادامه جدول نیز مشاهده می شود که محصولات پرفروش مبنای این دسته بندی قرار گرفته اند. در نتیجه، این خوشه بندی نتوانسته است گروه های مختلف را به خوبی تشخیص دهد.

Items that have the greatest role in distinguishing clusters

	Item	Chi_Square_Stat	P_value
38	cream	3898.000000	0.000000e+00
134	skin care	3898.000000	0.000000e+00
164	whole milk	426.945742	1.485487e-81
102	other vegetables	346.307584	1.242954e-64
130	sausage	262.617105	2.154979e-51
165	yogurt	212.558904	8.264306e-39
138	soda	212.360711	9.083168e-39
64	fruit/vegetable juice	198.242728	7.736230e-38
105	pastry	197.730639	9.586801e-36
156	tropical fruit	182.055939	1.614348e-32
20	canned beer	180.063617	4.914123e-34
11	bottled beer	171.506746	2.994998e-32
122	rolls/buns	167.812661	1.336839e-29
56	frankfurter	150.664787	6.422798e-28
12	bottled water	143.443969	1.206505e-24

۲. با در نظر گرفتن دومین سطر، با وجود اینکه **confidence** این قاعده نسبت به بقیه بیشتر می‌باشد؛ مقدار **lift** کمتر از ۱ می‌باشد و بیانگر مستقل بودن این دو آیتم می‌باشد. دلیل این تضاد این است که **confidence** تنها احتمال وقوع بخش نتیجه را در میان تراکنش‌های دارای بخش شرط اندازه‌گیری می‌کند و فراوانی کلی کالای موجود در بخش نتیجه را در نظر نمی‌گیرد. در نتیجه از آنجا که کالای موجود در بخش نتیجه از محصولات پرفروش است، مقدار **Confidence** افزایش می‌یابد، حتی اگر این دو آیتم از هم مستقل باشند. در مقابل، **lift** با در نظر گرفتن فراوانی کلی هر دو کالا، وابستگی واقعی بین آن‌ها را ارزیابی می‌کند؛ به همین دلیل، مقدار نزدیک ۱ برای **lift** نشان می‌دهد که بین این دو آیتم ارتباط معناداری وجود ندارد.

antecedents	consequents	antecedent support	consequent support	support	confidence	lift
(frankfurter)	(other vegetables)	0.037760	0.122101	0.005146	0.136283	1.116150
(bottled beer)	(whole milk)	0.045312	0.157923	0.007151	0.157817	0.999330
(sausage)	(whole milk)	0.060349	0.157923	0.008955	0.148394	0.939663
(newspapers)	(whole milk)	0.038896	0.157923	0.005614	0.144330	0.913926
(domestic eggs)	(whole milk)	0.037091	0.157923	0.005280	0.142342	0.901341